Guía de aprendizaje: Salud Mental en Adolescentes

Temas, fórmulas y reproducción del proyecto transversal

Sebastian Albornoz

2026-11-05

Tabla de contenidos

0.1 Propósito de esta guía 2
1 Contexto del proyecto 2
1.1 Pregunta de investigación 2
1.2 Artefactos del repositorio 2
1.3 Variables del dataset (16 columnas) 2
2 Estadística descriptiva 3
2.1 Tipos de variables 3
2.2 Medidas de tendencia central 3
2.2.a Media aritmética 3
2.2.b Mediana 3
2.2.c Moda 3
2.3 Medidas de posición no centrales (cuantiles) 3
2.3.a Cuartiles 3
2.3.b Deciles y percentiles 3
2.3.c Rango intercuartílico (IQR) 4
2.4 Regla de valores atípicos (diagrama de caja) 4
2.5 Interpretación de la forma (sesgo) 4
3 Tablas de frecuencia e histogramas 4
3.1 Intervalos de clase 4
3.2 Frecuencias 4
3.3 Histograma vs. diagrama de caja 5
4 Programación y reproducibilidad 5
4.1 Script bash (`scripts/descarga.sh`) 5
4.2 R, tidyverse y Quarto 5
4.3 Dashboard (raíz del proyecto) 5
4.4 Regresión lineal en el scatter del dashboard 5
5 Cómo reproducir todo el proyecto 5
5.1 Requisitos 5
5.2 Pasos (desde la raíz del repositorio) 6
5.3 Orden recomendado para estudiar 6
6 Mapa: qué muestra cada pantalla 7
6.1 Reporte EDA (contenido académico) 7
6.2 Dashboard (síntesis visual) 7

7 Glosario breve 7
8 Referencias internas 7

0.1 Propósito de esta guía

Este documento resume **qué enseña el proyecto**, **las fórmulas estadísticas** que aparecen en el reporte EDA y **cómo regenerar** cada artefacto (datos, reporte HTML, dashboard y esta guía en PDF). Está alineado con el repositorio *TrabajoProgramacionEstadistica* y con la consigna de Programación + Estadística descriptiva.

---

1 Contexto del proyecto

1.1 Pregunta de investigación

El dataset **Teen Mental Health** (Kaggle) registra hábitos digitales, sueño, rendimiento académico e indicadores de salud mental en adolescentes. El trabajo **no prueba causalidad** en sentido estricto; realiza un **análisis exploratorio (EDA)** para describir distribuciones, medidas de posición y relaciones visuales (por ejemplo, horas en redes vs. puntaje de riesgo).

1.2 Artefactos del repositorio

Artefacto	Archivo fuente	Salida	Rol
Descarga de datos	`scripts/descarga.sh`	`datos/dataset.csv`	CLI + limpieza inicial
Reporte EDA	`scripts/reporte_eda_salud_mental.qmd`	`reportes/reporte_eda_salud_mental.html`	Informe estadístico completo
Dashboard	`dashboard_salud_mental.qmd`	`docs/dashboard_salud_mental.html`	Visualización tipo curso (plotly + DT)
Proyecto Quarto	`_quarto.yml`	carpeta `docs/`	Sitio web / publicación

1.3 Variables del dataset (16 columnas)

Numéricas (magnitudes): edad, horas de redes, horas de sueño, pantalla antes de dormir, rendimiento académico, actividad física, niveles de estrés, ansiedad, adicción, puntaje de riesgo de salud mental.

Categóricas (etiquetas): género, plataforma, nivel de interacción social, calidad del sueño, bandera de bienestar digital. La variable `depression_label` viene codificada 0/1; en el reporte se trata como **categoría** para no mezclarla con medidas de tendencia central de variables continuas.

---

2 Estadística descriptiva

2.1 Tipos de variables

- **Cuantitativas (numéricas):** valores numéricos donde tiene sentido ordenar y (según el caso) promediar.
- **Cualitativas (categóricas):** modalidades; se describen con **frecuencias** y **moda**, no con media de la etiqueta.

2.2 Medidas de tendencia central

Sea una muestra de n valores observados $x_1, x_2, \ldots, x_n$ (solo valores no faltantes).

2.2.a Media aritmética

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

En R: `mean(x, na.rm = TRUE)`.

2.2.b Mediana

Valor que deja el 50 % de los datos ordenados por debajo y el 50 % por encima. Si n es impar, es el valor central; si n es par, suele tomarse el promedio de los dos centrales.

En R: `median(x, na.rm = TRUE)`.

2.2.c Moda

Valor (o valores) con **mayor frecuencia** en la muestra. Puede haber más de una moda.

En el proyecto: función `calcular_moda()` usando `table()` en R.

2.3 Medidas de posición no centrales (cuantiles)

2.3.a Cuartiles

- Q_1 (percentil 25): el 25 % de los datos ordenados es $\leq Q_1$.
- Q_2: coincide con la **mediana** (percentil 50).
- Q_3 (percentil 75): el 75 % de los datos ordenados es $\leq Q_3$.

En R: `quantile(x, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)`.

2.3.b Deciles y percentiles

- **Decil D_k:** valor que deja aproximadamente $10k$ % de los datos por debajo ($k = 1, \ldots, 9$).
- **Percentil P_p:** valor que deja p % de los datos por debajo ($p \in [0, 100]$).

En el reporte se calculan deciles D_1–D_9 con `quantile(..., probs = seq(0.1, 0.9, by = 0.1))` y percentiles como $P_5, P_{10}, P_{90}, P_{95}$.

2.3.c Rango intercuartílico (IQR)

$$\text{IQR} = Q_3 - Q_1$$

Resume la dispersión del **50 % central** de los datos.

2.4 Regla de valores atípicos (diagrama de caja)

Criterio clásico de Tukey usado en la tabla de interpretación del reporte:

$$L = Q_1 - 1{,}5 \cdot \text{IQR}, \qquad U = Q_3 + 1{,}5 \cdot \text{IQR}$$

Un valor x se considera **posible atípico** si $x < L$ o $x > U$. Los diagramas de caja de `ggplot2` marcan puntos fuera de bigotes construidos con la misma idea.

2.5 Interpretación de la forma (sesgo)

Comparando media y mediana (criterio del reporte):

- Si $\bar{x} \approx \tilde{x}$ (en el código: $|\bar{x} - \tilde{x}| < 0{,}05$): distribución **aproximadamente simétrica**.
- Si $\bar{x} > \tilde{x}$: **asimetría hacia la derecha** (cola hacia valores altos).
- Si $\bar{x} < \tilde{x}$: **asimetría hacia la izquierda**.

Esto es una **heurística visual**, no un test formal de normalidad.

---

3 Tablas de frecuencia e histogramas

3.1 Intervalos de clase

Para una variable numérica se particiona el rango en intervalos $[a_j, b_j)$ con:

- **Límite inferior** a_j y **límite superior** b_j
- **Amplitud** $A_j = b_j - a_j$
- **Marca de clase** (punto medio): $m_j = \frac{a_j + b_j}{2}$

En el proyecto, el número de intervalos sigue la regla de **Sturges**:

$$k = \lceil 1 + \log_2 n \rceil$$

y los cortes se ajustan con `pretty()` en R para obtener límites legibles.

3.2 Frecuencias

Para cada intervalo j, con n observaciones totales:

Concepto	Fórmula	Significado
Frecuencia absoluta	f_j	Cantidad de datos en el intervalo
Frecuencia relativa	$fr_j = f_j / n$	Proporción del total
Frecuencia porcentual	$fp_j = 100 \cdot fr_j$	Porcentaje
Frecuencia acumulada	$F_j = \sum_{i=1}^{j} f_i$	Suma hasta el intervalo j

En el reporte, los histogramas usan **los mismos cortes** que la tabla (`calcular_cortes()` + `cut()`), de modo que barras y tabla coinciden.

3.3 Histograma vs. diagrama de caja

- **Histograma:** altura de cada barra proporcional a f_j (intervalos adyacentes).
- **Diagrama de caja:** resume mediana, cuartiles y atípicos; útil para comparar dispersión sin ver todos los intervalos.

---

4 Programación y reproducibilidad

4.1 Script bash (`scripts/descarga.sh`)

Flujo:

1. Descarga el ZIP de Kaggle con `curl`.
2. Descomprime con `unzip`.
3. **Limpieza:** `sed` quita BOM UTF-8 del encabezado; `awk` elimina líneas vacías.
4. Escribe **`datos/dataset.csv`**.

Conceptos de materia: **CLI**, redirección, tuberías (`|`), reproducibilidad del dato crudo → dato listo para R.

4.2 R, tidyverse y Quarto

- **`read.csv` + `as_tibble()`:** importación.
- **`dplyr`:** `filter`, `summarise`, `group_by`, `mutate`, `across`.
- **`tidyr`:** `pivot_longer`, `pivot_wider` para tablas en formato largo.
- **`ggplot2`:** gráficos por capas (`aes`, `geom_*`, `facet_wrap`).
- **`knitr` + Quarto:** el `.qmd` mezcla Markdown, ecuaciones y chunks `{r}`; al **renderizar** se ejecuta R y se genera HTML/PDF.

4.3 Dashboard (raíz del proyecto)

Formato **`format: dashboard`** con:

- **Value boxes:** KPIs (observaciones, edad media, horas en redes, riesgo medio).
- **`ggplotly()`:** scatter interactivo (zoom, hover).
- **`DT::datatable()`:** tabla paginada y buscable.

No usa Shiny servidor: la interactividad va embebida en HTML (como el proyecto modelo del curso).

El archivo **`_quarto.yml`** declara `project: type: website` y `output-dir: docs`, por eso el render del dashboard cae en **`docs/`**.

4.4 Regresión lineal en el scatter del dashboard

`geom_smooth(method = "lm")` ajusta una recta $\hat{y} = a + bx$ por mínimos cuadrados entre horas en redes (x) y puntaje de riesgo (y). Es **descriptivo/visual**; no sustituye un modelo inferencial completo (no controla confusores ni supuestos).

---

5 Cómo reproducir todo el proyecto

5.1 Requisitos

- Git, Bash, R 4.x, RStudio (recomendado), Quarto.

- Paquetes R:

```
install.packages(c(
  "tidyverse", "knitr", "ggplot2", "plotly", "DT"
))
```

5.2 Pasos (desde la raíz del repositorio)

1. Datos

```
bash scripts/descarga.sh
# o, sin Kaggle:
cp datos/Teen_Mental_Health.csv datos/dataset.csv
```

2. Dashboard → `docs/`

```
quarto render dashboard_salud_mental.qmd
```

Abrir: `docs/dashboard_salud_mental.html`.

3. Reporte EDA → `reportes/`

```
quarto render scripts/reporte_eda_salud_mental.qmd --to html --output-dir ../
reportes
```

Abrir: `reportes/reporte_eda_salud_mental.html` (junto con `reporte_eda_salud_mental_files`).

4. Esta guía en PDF

```
quarto render guia_aprendizaje.qmd --to typst --output-dir reportes
```

Salida: `reportes/guia_aprendizaje.pdf`.

Si `quarto` no está en el PATH (Windows):

```
"/c/Program Files/Quarto/bin/quarto.exe" render guia_aprendizaje.qmd --to
typst --output-dir reportes
```

5.3 Orden recomendado para estudiar

1. Leer esta guía (conceptos y fórmulas).
2. Abrir el reporte HTML y seguir sección por sección con el `.qmd` en RStudio.
3. Explorar el dashboard y relacionar cada gráfico con las variables.
4. Modificar un chunk (por ejemplo, cambiar variable en un histograma) y volver a renderizar para ver el efecto.

---

6 Mapa: qué muestra cada pantalla

6.1 Reporte EDA (contenido académico)

1. Descripción del dataset (n, p).
2. Clasificación de variables.
3. Medidas de posición (central + cuantiles + deciles).
4. Tablas de frecuencia por intervalo.
5. Histogramas alineados con esas tablas.
6. Diagramas de caja.
7. Tabla de interpretación (forma + atípicos + cuartiles).

6.2 Dashboard (síntesis visual)

1. KPIs en value boxes.
2. Relación redes ↔ riesgo (plotly + recta LM).
3. Frecuencias de plataforma y bienestar digital.
4. Promedios de bienestar, boxplot estrés vs. calidad de sueño, histograma de riesgo.
5. Tabla completa con DT.

---

7 Glosario breve

- **EDA:** Exploratory Data Analysis; describir datos antes de modelar.
- **BOM:** Marca de orden de bytes al inicio de CSV exportados desde Excel.
- **Quarto:** Herramienta de publicación científica (sucesor spirit de R Markdown).
- **tidyverse:** conjunto de paquetes R con gramática común para datos tabulares.
- **Reproducibilidad:** otra persona (o vos en otro PC) puede obtener los mismos resultados siguiendo scripts y versiones documentadas.

---

8 Referencias internas

- Código del reporte: `scripts/reporte_eda_salud_mental.qmd`
- Código del dashboard: `dashboard_salud_mental.qmd`
- Instrucciones resumidas: `README.md`
- Dataset: `datos/dataset.csv` (origen Kaggle *teen-mental-health*)